

Predicción de Demanda con Modelos Avanzados y Ajuste Automático de Hiperparámetros

Arnau Sastre

[linkedin.com/in/arnausastre](https://www.linkedin.com/in/arnausastre)

August 10, 2025

Abstract

Este proyecto presenta un sistema avanzado de predicción de demanda que combina modelos de series temporales (**Prophet**, **ARIMA**) y modelos de machine learning (**LightGBM**). Mediante un proceso de validación cruzada y ajuste automático de hiperparámetros, se selecciona el modelo óptimo para minimizar el error de predicción. El enfoque es aplicable a contextos como retail, manufactura o logística, donde anticipar la demanda con precisión es clave para la toma de decisiones estratégicas.

1 Objetivo

Diseñar e implementar un pipeline de forecasting que:

- Limpie y prepare automáticamente datos de series temporales.
- Entrene y evalúe múltiples modelos de predicción.
- Seleccione el modelo con menor error de forma automatizada.
- Genere visualizaciones y métricas para facilitar la toma de decisiones.

2 Modelos utilizados

Se emplearon tres enfoques principales:

1. **Prophet**: modelo aditivo que maneja tendencia, estacionalidad y festivos.
2. **ARIMA**: modelo estadístico autoregresivo con media móvil.
3. **LightGBM**: algoritmo de gradient boosting para series temporales transformadas.

3 Metodología

El pipeline sigue los siguientes pasos:

1. Preprocesamiento de datos: limpieza, tratamiento de nulos y creación de variables de fecha.
2. Entrenamiento de los modelos y cálculo de métricas (MAE, RMSE, MAPE).
3. Selección automática del mejor modelo según error mínimo.
4. Generación de predicciones para el horizonte definido.

4 Métricas de evaluación

- **MAE** (Mean Absolute Error):

$$MAE = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|$$

- **RMSE** (Root Mean Squared Error):

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2}$$

- **MAPE** (Mean Absolute Percentage Error):

$$MAPE = \frac{100}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right|$$

5 Resultados

Tras evaluar los tres modelos, el sistema seleccionó automáticamente el que ofrecía el menor **MAPE**. Los resultados demostraron una mejora significativa frente a usar un único modelo estático. Además, las visualizaciones permitieron identificar patrones de estacionalidad y anomalías.

6 Aplicaciones reales

Este sistema puede integrarse en:

- **Retail**: previsión de ventas para optimizar inventarios.
- **Logística**: planificación de capacidad de transporte.
- **Manufactura**: ajuste de producción en función de la demanda prevista.

7 Conclusiones

La combinación de múltiples modelos y la selección automática mediante métricas objetivas permite obtener predicciones más precisas y robustas. Este enfoque reduce el riesgo de sobreajuste a un único modelo y se adapta mejor a datos con patrones cambiantes.

Contacto

Si quieres implementar un sistema similar en tu empresa, puedes escribirme a través de **LinkedIn** o **Malt**.